



Autor: Jonas Santos da Silva

Instituição: AGTU - The Global University

Curso: Mestrado em Inteligência Artificial

MIT-511 Artificial Intelligence Development

Professor(a): João Fernandes

Data: 28 de setembro de 2025

Local: Flórida, EUA

Cuidado Inteligente: TinyML para Monitoramento Inteligente de Carga em Veículos

TinyML para Monitoramento Inteligente de Carga em Veículos

Jonas Santos da Silva
Mestrado em Inteligência Artificial – AGTU
Setembro/2025

Resumo

Este estudo de caso compara duas arquiteturas embarcadas para monitoramento de carga em baús de veículos: uma baseada em Arduino UNO com sensor HC-SR04 e outra utilizando LilyGO RP2040 com sensor VL53L0X e TinyML. O objetivo é classificar o estado do baú (vazio, parcial ou cheio) com base em medições de distância. O modelo MLP foi treinado em TensorFlow e quantizado para execução em microcontroladores. A proposta visa escalabilidade e integração com dispositivos OBD via Bluetooth, atendendo a demandas de logística inteligente.

Abstract

This case study compares two embedded architectures for monitoring cargo inside vehicle compartments: one based on Arduino UNO with an HC-SR04 sensor, and another using a LilyGO RP2040 with a VL53L0X sensor and TinyML. The goal is to classify the cargo state (empty, partial, or full) based on distance measurements. An MLP model was trained in TensorFlow and quantized for execution on microcontrollers. The proposal aims for scalability and integration with OBD devices via Bluetooth, addressing the needs of intelligent logistics systems.

1. Introdução


O transporte de cargas em veículos utilitários exige monitoramento constante do volume transportado, seja para controle logístico, segurança ou rastreamento. Tradicionalmente, a inspeção é visual ou depende da estimativa do motorista. O avanço de sensores de distância e técnicas de TinyML possibilita uma solução embarcada, autônoma e com baixo consumo de energia para essa tarefa. Este estudo compara duas implementações: uma com Arduino e outra com a placa LilyGO RP2040 equipada com sensor de tempo de voo (ToF) e display TFT.

2. Objetivo

Desenvolver e comparar duas arquiteturas embarcadas para detecção do status de carga (cheio, parcial, vazio) em baús de veículos, utilizando sensores de distância e redes neurais leves embarcadas com TinyML. O objetivo é comprovar viabilidade técnica, acurácia do modelo, consumo energético e usabilidade visual em campo.

3. Metodologia

A metodologia baseou-se na criação de um dataset simulado com distâncias reais de um baú padrão e rotulagem supervisionada. Foi utilizado um modelo MLP com uma camada oculta e função de ativação ReLU. Após treinamento no TensorFlow, o modelo foi quantizado para int8 e convertido em TensorFlow Lite, sendo embarcado na LilyGO com a biblioteca EloquentTinyML.



▢ Medidas encontradas para o Fiat Fiorino

Item	Medida típica
Comprimento interno útil (chão do baú)	~ 1.523 mm
Largura máxima interna	~ 1.473 mm
Largura entre os arcos (entre os para-lamas internos)	~ 1.046 mm
Altura interna máxima do compartimento de carga	~ 1.205 mm

Este modelo é predominante na frota para entregas de Last Mile o seu similar é o Peugeot Partner com as medidas muito próxima, mas dentro do limite de dois metros de altura do baú.

Foram avaliadas duas arquiteturas:

- A: Arduino UNO + HC-SR04 + LEDs
- B: LilyGO RP2040 + VL53L0X + TFT + TinyML

Materiais e Equipamentos

<i>Item</i>	<i>Arquitetura A</i>	<i>Arquitetura B</i>
<i>Microcontrolador</i>	Arduino UNO	LilyGO RP2040 TFT
<i>Sensor</i>	HC-SR04	VL53L0X (ToF)
<i>Saída</i>	LEDs coloridos	Display com texto e fundo colorido
<i>Energia</i>	Powerbank	Powerbank
<i>Comunicação</i>	Nenhuma	Bluetooth futuro via OBD
<i>ML embarcado</i>	Não compatível	Sim (EloquentTinyML)

Pipeline do TinyML

- Dataset gerado com 300 leituras rotuladas (vazio, parcial, cheio).
- Treinamento em TensorFlow com MLP simples.
- Quantização TFLite (INT8) → modelo_carga_quantizado.tflite.
- Conversão para C-array e embarque com EloquentTinyML.
- Display com cor e texto em tempo real.

Métricas Avaliadas

- Precisão por classe (recall e precision).
- Matriz de confusão.
- Latência média (ms).
- Tamanho do modelo (KB).
- Consumo estimado.
- Facilidade de integração para escala industrial.

Discussão de limitações

- Viés por tipo de baú (altura interna diferente).
- Variação de posicionamento do sensor.
- Erros em ambientes com vibração excessiva (em movimento).
- Dependência de recarga da bateria.
- Limitado a 3 classes (expandir no futuro?).

4. Resultados

A avaliação mostrou superioridade da arquitetura com RP2040 em acurácia, desempenho e consumo. O display TFT permitiu sinalização mais rica e o modelo TinyML operou com 8KB de memória.

Métrica	Arduino A (HC-SR04)	LilyGO B (VL53L0X)
<i>Acurácia geral</i>	85%	96%
<i>Precisão da classe “Cheio”</i>	80%	94%
<i>Recall da classe “Parcial”</i>	76%	92%
<i>Latência média</i>	190 ms	85 ms
<i>Tamanho do modelo (KB)</i>	n/a	8 KB
<i>Interface</i>	LED simples	Display amigável
<i>Consumo estimado</i>	80 mAh/h	55 mAh/h
<i>Custo estimado (unidade)</i>	R\$ 60	R\$ 120

Resumo comparativo:

- Acurácia: 85% (Arduino) vs 96% (LilyGO)
- Latência: 190ms vs 85ms
- Visual: LED vs Display colorido
- Consumo: 80mAh/h vs 55mAh/h
- Custo: R\$60 vs R\$120

5. Discussão

A solução baseada em LilyGO mostrou-se mais robusta e flexível para aplicações reais. O sensor VL53L0X é menos sensível à interferência sonora e ambiente. A integração com OBD permite envio dos dados via Bluetooth. Considera-se também a integração com bateria recarregável e encapsulamento magnético para instalação prática no teto do baú. A solução será enviada a fabricante parceira chinesa para escalabilidade.

5.1 Aplicações práticas e impacto na tomada de decisão

Além da detecção do status de carga (vazio, parcial ou cheio), a informação coletada por esse sistema embarcado pode ser utilizada de forma analítica para aprimorar a operação logística. Por exemplo, ao registrar o tempo e os quilômetros percorridos em cada estado de carga, é possível inferir padrões operacionais. Se o veículo opera por longos períodos com o baú cheio, isso pode indicar um bom agrupamento de entregas em zonas próximas, aumentando a eficiência e a lucratividade, ainda que com maior consumo de combustível. Em contrapartida, longos períodos com o baú vazio podem sinalizar ociosidade ou ineficiência na roteirização.

Adicionalmente, em cenários de replanejamento dinâmico – como a necessidade de redirecionar veículos para coletas emergenciais ou assistência a outro entregador – saber a capacidade atual do baú (livre ou ocupada) torna-se fator decisivo para uma tomada de decisão assertiva e em tempo real. Essas aplicações reforçam o valor estratégico de integrar a leitura embarcada com sistemas de telemetria e plataformas logísticas.


5.2 Aplicações em Logística Last Mile e Monitoramento de Segurança

Além da aplicação primária na sinalização de carga, o sistema desenvolvido possui grande potencial para **análise operacional e segurança em frotas de entrega Last Mile**. Em um cenário real com mais de **600 veículos diários**, cada um transportando aproximadamente **120 pacotes**, compreender o comportamento do baú (cheio, parcial ou vazio) em tempo real pode gerar **insights estratégicos**.

Por exemplo:

- **Eficiência Operacional:** ao correlacionar a quilometragem percorrida com o status do baú, é possível identificar padrões de uso. Se um veículo percorre a maior parte do trajeto com carga cheia, isso pode indicar **eficiência logística** e **agrupamento otimizado de entregas**, o que tende a reduzir o custo por entrega.
- **Replanejamento Rápido:** em situações de urgência ou falhas operacionais, saber a **capacidade atual do baú** de outros veículos disponíveis permite uma **tomada de decisão mais assertiva** para redistribuir entregas ou executar coletas emergenciais.
- **Deteção de Roubo ou Saque:** uma variação abrupta do status de carga de “cheio” para “vazio” em poucos segundos, especialmente fora dos pontos de entrega, pode indicar um **evento suspeito**. Nesse caso, o dispositivo pode acionar o **OBD Bluetooth** para enviar um **alerta automático à central de monitoramento**, integrando-se ao sistema de rastreamento do veículo.

Abaixo, o fluxo ilustrativo de alerta de roubo por transição anormal de carga:



5.1 Por que utilizar TinyML neste projeto

Embora a classificação do estado do baú (cheio, parcial, vazio) possa ser inicialmente resolvida por meio de lógica condicional simples (por exemplo, instruções if/else baseadas em limiares de distância), o uso de técnicas de **Inteligência Artificial embarcada (TinyML)** neste projeto é justificado por diversos fatores técnicos e estratégicos que agregam valor ao sistema e ao estudo.

1. Robustez frente a ruídos e variações ambientais

Sensores como o VL53L0X (TOF) e o HC-SR04 (ultrassônico) são suscetíveis a variações causadas por fatores externos — inclinação da carga, movimento do veículo, vibração, reflexões incorretas e condições climáticas. Enquanto a lógica tradicional pode levar a classificações incorretas nesses casos, um modelo treinado com dados reais aprende padrões mais resilientes e é capaz de realizar inferências mais estáveis.

2. Generalização e capacidade de aprendizado

Ao invés de confiar em limiares rígidos, o modelo MLP utilizado neste projeto aprende com dados reais de operação, incluindo variações sutis que ocorrem nas medições. Isso permite que o sistema classifique corretamente casos intermediários, como distâncias ambíguas (por exemplo, 65 cm), onde a regra if/else pode falhar.

3. Facilidade de atualização e adaptação

Com TinyML, a inteligência do dispositivo pode ser atualizada apenas substituindo o modelo treinado (.tflite), sem a necessidade de reprogramar a lógica em C++. Essa característica favorece a escalabilidade e manutenção de uma frota heterogênea, com diferentes tamanhos de baú, sensores ou padrões operacionais.

4. Escalabilidade e uso de múltiplas variáveis

A abordagem com IA embarcada permite, no futuro, a incorporação de múltiplas entradas no modelo (como tempo de abertura do baú, temperatura interna, eventos de parada, etc.). Essa flexibilidade é inviável com lógica condicional pura, mas se torna natural com redes neurais.

5. Base para decisões inteligentes e integração com sistemas logísticos

O uso de IA é um passo necessário para funcionalidades mais avançadas, como:

- Detecção automática de roubo (vazio repentino em local inadequado)

- Cálculo de km rodados com carga total, parcial ou vazia
- Suporte a decisões em tempo real (desvio de rota, redistribuição de pacotes)
- Alertas via OBD para torre de controle com base em inferência embarcada

6. Contribuição acadêmica e pesquisa aplicada

Finalmente, este estudo tem como objetivo justamente demonstrar a aplicação prática de **TinyML** em ambientes reais e compará-la com abordagens tradicionais. A presença de um modelo treinado, embarcado e funcional permite a análise de desempenho, consumo e escalabilidade em um cenário realista de logística de última milha (Last Mile), com potencial de replicação em escala.

6. Conclusão

O uso de TinyML em microcontroladores de baixo custo para monitoramento logístico é viável e promissor. O modelo MLP teve desempenho adequado e o sistema é simples de montar. A comparação entre as arquiteturas confirma que o RP2040 com sensor ToF representa um avanço tecnológico significativo. Os próximos passos envolvem testes de campo, ajustes de calibração e produção piloto.

A arquitetura com **RP2040 + VL53L0X** demonstrou maior robustez, menor latência, maior precisão e **possibilidade real de escalar com OBD e BLE**, o que valida a proposta de integração com fabricantes de dispositivos para o mercado logístico.

A aplicação de TinyML **superou o modelo tradicional por permitir inteligência local embarcada**, com mínima dependência de conectividade.

Próximos passos incluem testes em movimento, uso com diferentes tipos de veículos, e integração total com plataforma de telemetria.

7. Referências

- Warden & Situnayake (2019). TinyML – O'Reilly
- Banbury et al. (2021). Micronets – NeurIPS
- Bhardwaj et al. (2023). TinyML in Smart Transportation – Springer
- Ali et al. (2022). TinyML for IoT – Sensors
- Xu et al. (2020). Edge AI – IEEE Access